

第六章 概率

dovego

2026 年 6 月 3 日

1 随机事件的条件概率

1.1 条件概率的概念

我们称

$$P(B|A) = \frac{P(AB)}{P(A)}$$

为在事件 A 发生的条件下事件 B 发生的条件概率.

可以通过 Venn 图来帮助理解.

思考交流

1. 概率 $P(B|A)$ 与 $P(AB)$ 有什么区别和联系?

答: (1) $P(B|A) \geq P(AB)$. 因为 $P(A) \in (0, 1]$.

(2) 求 $P(B|A)$ 时考虑的样本空间中的样本点为事件 A 发生时的样本点, 而求 $P(AB)$ 时考虑的样本空间为整个样本空间 Ω . 前者小于后者.

2. 若 B 和 C 是两个互斥事件, 则 $P[(B \cup C)|A] = P(B|A) + P(C|A)$ 是否成立?

答: 成立. 因为 B 与 C 互斥, 所以 AB 与 AC 互斥. 由互斥事件的加法原理

$$\begin{aligned} P(B|A) + P(C|A) &= \frac{P(AB)}{P(A)} + \frac{P(AC)}{P(A)} \\ &= \frac{P(AB) + P(AC)}{P(A)} \\ &= \frac{P[A(B \cup C)]}{P(A)} \\ &= P[(B \cup C)|A]. \end{aligned}$$

该公式还可以推广到 n 个事件的情况.

1.2 乘法公式与事件的独立性

乘法公式:

$$P(AB) = P(A)P(B|A).$$

利用它可以计算两个事件同时发生的概率.

拓展 (乘法公式的推广) 若 $P(A_1 A_2 \cdots A_n) > 0$, 则

$$P(A_1 A_2 \cdots A_n) = P(A_1)P(A_2|A_1)P(A_3|A_1 A_2) \cdots P(A_n|A_1 A_2 \cdots A_{n-1}).$$

下面的例 3 就对该公式在 $n = 3$ 时进行了推导.

例 3 已知口袋中有 3 个黑球和 7 个白球, 这 10 个球除颜色外完全相同.

(2) 从中不放回地摸球, 每次各摸一球, 求第三次才摸到黑球的概率.

解 设事件 A_i 表示“第 i 次摸到黑球”, 事件 A 表示“第三次才摸到黑球”, 则 $A = \overline{A_1} \overline{A_2} A_3$.

由题意知 $P(\overline{A_1}) = \frac{7}{10}, P(\overline{A_2}|\overline{A_1}) = \frac{6}{9}, P(A_3|\overline{A_1} \overline{A_2}) = \frac{3}{8}$.
于是, 根据乘法公式有

$$\begin{aligned} P(\overline{A_1} \overline{A_2} A_3) &= P(\overline{A_1} \overline{A_2})P(A_3|\overline{A_1} \overline{A_2}) \\ &= P(\overline{A_1})P(\overline{A_2}|\overline{A_1})P(A_3|\overline{A_1} \overline{A_2}) \\ &= \frac{7}{10} \times \frac{6}{9} \times \frac{3}{8} \\ &= \frac{7}{40}. \end{aligned}$$

所以不放回地摸球, 第三次才摸到黑球的概率为 $\frac{7}{40}$.

若事件 A 与事件 B 相互独立, 则应有 $P(B) = P(B|A)$. 由此可以证得

$$\text{事件 } A \text{ 与事件 } B \text{ 相互独立} \iff P(AB) = P(A)P(B).$$

但当三个事件 A, B, C 两两独立时, 等式 $P(ABC) = P(A)P(B)P(C)$ 一般不成立!!! 只有说 A, B, C 三个事件相互独立时才满足该式 (三者相互独立 $\Rightarrow$ 两两独立, 反之不一定成立!!!).

要计算三个事件同时发生的概率, 一般需要利用条件概率计算, 例如

$$P(ABC) = P(A)P(B|A)P(C|AB).$$

例 4 告诉我们, 要判断事件 A, B 是否独立, 有以下两种方法:

(1) 判断 $P(B|A) = P(B)$ 是否成立;

(2) 判断 $P(AB) = P(A)P(B)$ 是否成立.

补充 常见的独立事件: 有放回摸球试验, 掷骰子, 掷硬币, 产品质量检测.

1.3 全概率公式

设 Ω 是试验 E 的样本空间, $B_1, B_2, \dots, B_n$ 为样本空间 Ω 的一组事件, 若

(1) $B_i B_j = \emptyset$, 其中 $i \neq j (i, j = 1, 2, \dots, n)$,

(2) $B_1 \cup B_2 \cup \dots \cup B_n = \Omega$,

则称 $B_1, B_2, \dots, B_n$ 为样本空间 Ω 的一个划分.

全概率公式 设 $B_1, B_2, \dots, B_n$ 为样本空间 Ω 的一个划分, 若 $P(B_i) > 0 (i = 1, 2, \dots, n)$, 则对任意一个事件 A 有

$$P(A) = \sum_{i=1}^n P(B_i)P(A|B_i).$$

称上式为全概率公式.

这个公式告诉我们, 事件 A 发生的概率是事件 A 在这些“原因” (B_i) 下发生的条件概率的平均, 可以看成“由原因推结果”.

贝叶斯公式 设 $B_1, B_2, \dots, B_n$ 为样本空间 Ω 的一个划分, 若 $P(A) > 0, P(B_i) > 0 (i = 1, 2, \dots, n)$, 则

$$P(B_i|A) = \frac{P(B_i)P(A|B_i)}{\sum_{j=1}^n P(B_j)P(A|B_j)}.$$

称上式为贝叶斯公式.

这个公式的思想是“执果溯因”, 已知事件 A 发生的情况下, 寻找每个原因的概率.

全概率公式和贝叶斯公式都是新教材添加的内容, 说明对概率的理解要更加深入.

2 离散型随机变量及其分布列

2.1 随机变量

将样本空间中的每一个样本点都和一个确定的数值 (实数) 对应起来, 在这个对应下, 数值会随着试验结果的变化而变化. 将这种数值随着试验结果的变化而变化的量称为**随机变量**, 常用字母 X, Y, ξ, η 等来表示.

随机变量 X 的一个取值代表一个试验结果. 随机变量一些取值构成的集合表示一个随机事件, 例如: $\{X = 6\}$ 表示事件“掷出的点数为 6”, $\{X < 3\}$ 表示事件“掷出的点数小于 3”.

2.2 离散型随机变量的分布列

取值能够一一列举出来 (不论是否有限) 的随机变量叫做**离散型随机变量**. 若离散型随机变量 X 的取值为 $x_1, x_2, \dots, x_n, \dots$, 随机变量 X 取 x_i 的概率为 $p_i (i = 1, 2, \dots, n, \dots)$, 记作

$$P(X = x_i) = p_i (i = 1, 2, \dots, n, \dots). \quad (1)$$

(1)式也可以列成表, 如表 1:

表 1

x_i	x_1	x_2	$\cdots$	x_n	$\cdots$
$P(X = x_i)$	p_1	p_2	$\cdots$	p_n	$\cdots$

表 1 或(1) 称为**离散型随机变量 X 的分布列**, 简称 **X 的分布列**.

显然:

(1) $p_i > 0 (i = 1, 2, \dots, n, \dots)$;

(2) $p_1 + p_2 + \cdots + p_n + \cdots = 1$.

称随机变量 X 满足这一分布列, 记作

$$X \sim \begin{pmatrix} x_1 & x_2 & \cdots & x_n & \cdots \\ p_1 & p_2 & \cdots & p_n & \cdots \end{pmatrix}.$$

伯努利试验 每次试验只有两个对立结果, 可以分别称为“成功”和“失败”, 每次“成功”的概率均为 p , 每次“失败”的概率均为 $1 - p$.

若随机变量 X 的分布列如表 2:

表 2

X	1	0
P	p	q

其中 $0 < p < 1, q = 1 - p$, 那么称离散型随机变量 X 服从参数为 p 的两点分布 (又称 **0-1 分布** 或 **伯努利分布**). 购买彩票是否中奖, 婴儿的性别, 投篮是否命中等, 都可以用两点分布来描述.

3 离散型随机变量的均值与方差

3.1 离散型随机变量的均值

我们称

$$EX = x_1p_1 + x_2p_2 + \cdots + x_ip_i + \cdots + x_np_n$$

为随机变量 X 的**均值**或**数学期望** (简称**期望**). 数学期望 EX 刻画了随机变量取值的“中心位置”, 但其并不能完全决定随机变量的性质. 随机变量的分布完全确定了它的均值, 不同的分布可以有相同的均值.

两点分布的均值为

$$\begin{aligned} EX &= 0 \cdot P(X = 0) + 1 \cdot P(X = 1) \\ &= 0 \cdot (1 - p) + 1 \cdot p \\ &= p. \end{aligned}$$

3.2 离散型随机变量的方差

我们知道, 样本方差 (初中知识, 也可参看必修一第六章 §4.4.1 样本的数字特征) 可以度量一组样本数据的离散程度. 对于随机变量, 也可以借鉴类似的思想.

我们称 DX 为随机变量 X 的**方差**, 其算术平方根 $\sqrt{DX}$ 为随机事件 X 的**标准差**, 记作 σ_X .

$$\begin{aligned} DX &= E(X - EX)^2 = \sum_{i=1}^n (x_i - EX)^2 p_i \\ &= E(X^2 - 2XEX + (EX)^2) = EX^2 - (EX)^2. \end{aligned}$$

方差 DX 为这些偏离程度的加权平均. DX 和 σ_X 都反映了随机变量的取值偏离均值的平均程度.

计算离散型随机变量 X 的方差 DX 的一般过程如下:

- (1) 计算每一个 $P(X = i) = p_i$;
- (2) 计算期望 $EX = \sum_{i=1}^n x_i p_i$;
- (3) 计算 $DX = E(X - EX)^2 = \sum_{i=1}^n (x_i - EX)^2 p_i$.

两点分布的方差为:

$$DX = E(X - EX)^2 = p(1 - p).$$

4 二项分布与超几何分布

4.1 二项分布

n 重伯努利试验: 在相同的条件下, 进行 n 次伯努利试验, 且每次试验相互独立.

二项分布 一般地, 在 n 重伯努利试验中, 用 X 表示这 n 次试验中成功的次数, p 为每次试验成功的概率, 则 X 的分布列可以表示为

$$P(X = k) = C_n^k p^k (1 - p)^{n-k} (k = 0, 1, 2, \dots, n).$$

若随机变量 X 的分布列如上所述, 则称 X 服从参数为 n, p 的二项分布, 简记为 $X \sim B(n, p)$. 两点分布就是 $n = 1$ 时的二项分布.

二项分布的期望与方差为:

$$EX = \sum_{k=0}^n k C_n^k p^k (1 - p)^{n-k} = np,$$

$$DX = np(1 - p).$$

当 $n = 1$ 时就是两点分布的期望与方差.

EX 的证明如下:

由 $kC_n^k = nC_{n-1}^{k-1}$, 得

$$EX = n \sum_{k=1}^n C_{n-1}^{k-1} p^k (1 - p)^{n-k} = np \sum_{k=1}^n C_{n-1}^{k-1} p^{k-1} (1 - p)^{(n-1)-(k-1)}.$$

令 $m = k - 1$, 由二项式定理得

$$EX = np \sum_{m=0}^{n-1} C_{n-1}^m p^m (1-p)^{(n-1)-m} = np[p + (1-p)]^{n-1} = np.$$

DX 可由 $DX = EX^2 - (EX)^2$ 证得, 略为复杂.

4.2 超几何分布

一般地, 设有 N 件产品, 其中有 M 件次品. 从中任取 $n (n \leq N)$ 件产品, 用 X 表示取出的 n 件产品中次品的件数, 那么

$$P(X = k) = \frac{C_M^k C_{N-M}^{n-k}}{C_N^n}, \max\{0, n - (N - M)\} < k < \min\{n, M\}.$$

其中 $n \leq N, M \leq N, N \in \mathbf{N}_+$.

若随机变量 X 的分布列如上所述, 则称 X 服从参数为 N, M, n 的超几何分布.

超几何分布的期望 EX 为:

$$EX = \sum_{k=m}^r k \frac{C_M^k C_{N-M}^{n-k}}{C_N^n} = \frac{nM}{N}.$$

其中 $m = \max\{0, n - (N - M)\}, n = \min\{n, M\}$.

EX 的证明如下:

i) 先证 $\sum_{k=m}^r C_{M-1}^{k-1} C_{N-M}^{n-k} = C_{N-1}^{n-1}$.

右边表示在 $N - 1$ 件产品中任选 $n - 1$ 件的总抽法数. 这是一个组合问题, 现在我们将这 $N - 1$ 件产品分为 $M - 1$ 件次品和 $N - M$ 件正品. 那么原先的组合问题就可以分解为 $n - 1$ 件中 “恰好抽到 m 件次品” “恰好抽到 $m + 1$ 件次品” ... “恰好抽到 r 件次品” 这若干个互斥事件. 于是原问题的总抽法数便等于这若干个互斥事件的抽法数之和. 若 $n - 1$ 件中抽到 k 件次品, 则有 $C_{M-1}^k C_{N-M}^{n-k}$ 种方法. 因此: 分情况累加的总抽法 (左边) = 不分情况直接抽的总抽法 (右边). 即

$$\sum_{k=m}^r C_{M-1}^{k-1} C_{N-M}^{n-k} = C_{N-1}^{n-1}.$$

ii) 再证期望公式.

当 $m > 0$ 时, 由 $kC_M^k = MC_{M-1}^{k-1}$, $C_N^n = \frac{n}{N}C_{N-1}^{n-1}$ 得

$$EX = \frac{nM}{N} \cdot \frac{1}{C_N^n} \cdot \sum_{k=m}^r C_{M-1}^{k-1} C_{N-M}^{n-k} = \frac{nM}{N}.$$

当 $m = 0$ 时, 类似可证明结论依然成立.

4.3 正态分布

正态分布是最常见、最重要的连续随机变量的分布, 是刻画误差分布的重要模型, 因此也称为**误差分布**. 记作 $X \sim N(\mu, \sigma^2)$. 其中 $EX = \mu$, $DX = \sigma^2$. 其分布密度函数的解析式为:

$$\varphi_{\mu, \sigma} = \frac{1}{\sqrt{2\pi}\sigma} e^{-\frac{(x-\mu)^2}{2\sigma^2}}, x \in (-\infty, +\infty).$$

函数图像关于 $x = \mu$ 对称, 随着 μ 的变化而平移. 当 μ 确定时, σ 越小, 总体分布越集中; σ 越大, 总体分布越分散.

正态分布随机变量 X 在区间 $(a, b]$ 上取值的概率 $P(a < X \leq b)$ 就是分布曲线在区间 $(a, b]$ 对应的曲边梯形面积的值. 特别地,

- (1) $P(\mu - \sigma < X < \mu + \sigma) = 0.683$,
- (2) $P(\mu - 2\sigma < X < \mu + 2\sigma) = 0.954$,
- (3) $P(\mu - 3\sigma < X < \mu + 3\sigma) = 0.997$.

通常认为服从正态分布的随机变量 X 只取区间 $(\mu - 3\sigma, \mu + 3\sigma]$ 之间的值, 称为 **3 σ 原则**. 并认为 X 在此区间之外取值几乎不可能发生, 是小概率事件.